

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Analiza składników różnych przepisów kulinarnych

Wersja dokumentu: 1.0

Data: 07.06.2026

Autorzy: Karolina Rybak, Hanna Jermakowicz, Anna Martyniuk

1. Wprowadzenie

Niniejszy dokument opisuje specyfikację wymagań dla skryptu R, którego celem jest zbadanie i zaprezentowanie zawartości bazy przepisów kulinarnych z pliku CSV. Analiza danych tekstowych opiera się na trzech technikach takich jak analiza częstości słów, podejście TF-IDF zastosowane w nowoczesnej architekturze z agregacją maksymalną oraz analiza asocjacji realizowana poprzez transformację oczyszczonych ciągów tekstowych do macierzy TDM. Generowane są zestawienia statystyczne oraz wizualizacje w postaci chmury słów i wykresów lizakowych.

2. Cele systemu

- Wczytanie bazy danych z pliku CSV (kodowanie Windows-1252)
- Oczyszczanie danych, eliminacja symboli oraz odfiltrowanie nieistotnych słów
- Agregacja danych, zliczenie globalnej częstości występowania składników i wizualizacja bazy w postaci chmury słów
- Wyodrębnienie najbardziej wyrazistych i charakterystycznych składników dań poprzez analizę najwyższych punktowych wartości unikalności wyliczonych metodą TF-IDF
- Przekształcenie danych do macierzy TDM i obliczenie korelacji liniowych dla wybranych słów kluczowych
- Wizualizacja wyników za pomocą wykresów lizakowych
- Umożliwienie analizy unikalnych składników na podstawie czterech odrębnych światów kulturowo-kulinarnych

3. Wymagania funkcjonalne

- **Wczytywanie danych:**
 - Skrypt powinien umożliwiać wczytanie danych z lokalnego pliku CSV
 - Skrypt powinien automatycznie generować unikalny indeks numeryczny dla każdego wiersza
- **Przetwarzanie i oczyszczanie tekstu:**
 - Skrypt powinien dokonywać bezpiecznej konwersji bajtowej plików wejściowych
 - Skrypt powinien umożliwiać normalizację znaków do małych liter i usuwanie symboli
 - Skrypt powinien przeprowadzać podział tekstu na pojedyncze składniki kulinarne
 - Skrypt powinien odfiltrowywać słowa nieistotne
 - Skrypt powinien usuwać zbędne spacje oraz puste i za krótkie słowa
- **Analiza częstości:**
 - Skrypt powinien umożliwiać zliczenie liczby wystąpień słów oraz sortować je malejąco
 - Skrypt powinien prezentować wyniki w formie tabeli i chmury słów

- **Analiza TF-IDF:**
 - Skrypt powinien przeprowadzać analizę ważenia statystycznego i agregować wskaźniki dla każdego unikalnego słowa
 - Skrypt powinien prezentować wyniki w formie tabeli i chmury słów
- **Analiza asocjacji:**
 - Skrypt powinien przekształcać oczyszczone ciągi składników do macierzy TDM
 - Skrypt powinien przeszukiwać macierz TDM w pętli dla zestawu słów kluczowych
 - Skrypt powinien obliczać współczynnik korelacji liniowej Pearsona i filtrować wyniki dla zadanego progu odcięcia
- **Wizualizacja danych:**
 - Skrypt powinien generować cztery wykresy lizakowe do maksymalnie 25 największych wyników

4. Wymagania niefunkcjonalne

- **Wydajność:**
 - Analiza pełnej bazy przepisów (ok. 5 475 rekordów) wraz z wygenerowaniem wszystkich wizualizacji powinna trwać nie dłużej niż 60 sekund na typowym komputerze osobistym.
- **Bezpieczeństwo:**
 - System powinien zapewniać poprawność i kompletność danych wyjściowych.
 - System powinien przetwarzać dane wyłącznie lokalnie, bez przesyłania ich na zewnątrz.
- **Niezawodność:**
 - Skrypt powinien poprawnie obsługiwać różne zapisy składników oraz znaki specjalne występujące w nazwach handlowych.
 - Skrypt powinien poprawnie obsługiwać puste i zbyt krótkie tokeny oraz słowa kluczowe, dla których nie istnieją asocjacje powyżej progu odcięcia (bez przerywania działania).
 - Ustawione ziarno losowości powinno zapewniać powtarzalność układu chmur słów przy każdym uruchomieniu skryptu.
- **Użyteczność:**
 - Wykresy lizakowe powinny zawierać tytuł, etykiety osi, wartości liczbowe oraz legendę.
 - Chmury słów powinny być generowane z czytelną kolorystyką (RColorBrewer).
 - Raport HTML powinien zawierać spis treści oraz możliwość zwijania bloków kodu.
- **Kompatybilność:**
 - Skrypt powinien być kompatybilny z R w wersji 4.0 lub nowszej.

- Skrypt powinien korzystać z bibliotek: tidyverse, tidytext, tm, wordcloud, RColorBrewer.

5. Interfejsy użytkownika

- **Wejście:**
 - Plik tabelaryczny .csv
- **Wyjście:**
 - Tabela z globalną częstością słów
 - Tabela z wagami unikalności
 - Chmura częstości słów oraz chmura unikalności
 - Wykresy lizakowe relacji współwystępowania składników

6. Wymagania dotyczące danych

Dane wejściowe znajdują się w pliku recipes.csv (ok. 5 475 rekordów) i są zapisane w języku angielskim. Plik zawiera następujące kolumny:

Kolumna	Opis
id	Tekstowy identyfikator przepisu.
recipeName	Nazwa przepisu.
rating	Ocena przepisu.
totalTimeInSeconds	Łączny czas przygotowania (w sekundach).
course	Typ dania (np. Desserts) — zapisany w nawiasach kwadratowych.
cuisine	Rodzaj kuchni (np. American) — zapisany w nawiasach kwadratowych.
ingredients	Lista składników w nawiasach kwadratowych, rozdzielona przecinkami — podstawowe pole analizy.

- Dane tekstowe są w języku angielskim; skrypt nie obsługuje analizy dla innych języków.
- Kluczowym polem analizy jest kolumna ingredients — lista składników w nawiasach kwadratowych, rozdzielona przecinkami.
- Pole ingredients zawiera znaki specjalne (znaki towarowe ® oraz ™) w nazwach handlowych składników, wymagające odpowiedniej obsługi na etapie wczytywania danych.
- System nie obsługuje danych z innych źródeł ani formatów niż plik CSV o opisanej powyżej strukturze.

Słownictwo dokumentacji

- **Token:** pojedynczy element tekstu (w tym projekcie — pojedynczy składnik lub słowo).

- **Składnik (ingredient):** element listy składników danego przepisu.
- **Słowa nieistotne:** słowa pomijane w analizie, tu m.in. składniki pomocnicze i przymiotniki opisowe.
- **Częstość globalna:** łączna liczba wystąpień danego składnika w całej bazie przepisów.
- **Chmura słów (wordcloud):** graficzna prezentacja słów, w której rozmiar słowa odzwierciedla jego wagę.
- **TF (Term Frequency):** częstość występowania składnika w obrębie pojedynczego przepisu.
- **IDF (Inverse Document Frequency):** miara rzadkości składnika w całej bazie przepisów.
- **TF-IDF:** iloczyn TF i IDF; wysoka wartość wskazuje składnik charakterystyczny dla danego przepisu.
- **Waga unikalności:** wartość TF-IDF interpretowana jako stopień charakterystyczności składnika.
- **Korpus (corpus):** uporządkowany zbiór dokumentów tekstowych.
- **Macierz TDM (TermDocumentMatrix):** macierz częstości terminów w poszczególnych dokumentach, stanowiąca podstawę analizy asocjacji.
- **Asocjacja:** statystyczne powiązanie współwystępowania dwóch terminów.
- **Korelacja Pearsona:** miara siły liniowego współwystępowania terminów
- **Próg odcięcia (corlimit):** minimalna wartość korelacji, powyżej której asocjacja jest uwzględniana w wynikach.
- **Cztery światy kulturowo-kulinarne:** zidentyfikowane w analizie grupy składników odpowiadające profilom kulinarnym (cukierniczy, azjatycki, grillowy, włoski).

Przypadki użycia (use cases)

Aktor: Użytkownik

- wczytuje plik recipes.csv,
- uruchamia analizę,
- przegląda tabele wyników (globalna częstość, wagi unikalności),
- przegląda wizualizacje (chmury słów oraz wykresy lizakowe).

Aktor: Skrypt / System

- wczytuje dane i nadaje każdemu wierszowi indeks numeryczny,
- oczyszcza i normalizuje listy składników,
- zlicza globalną częstość składników,
- oblicza wagi TF-IDF z agregacją maksymalną,
- przekształca dane do macierzy TDM i oblicza korelacje Pearsona,
- generuje chmury słów (częstości i unikalności) oraz cztery wykresy lizakowe.

Testowe przypadki użycia

- Test z pełną bazą recipes.csv (poprawne wczytanie ~5 475 rekordów).
- Test ze składnikami zawierającymi znaki towarowe (®, ™) - weryfikacja poprawnego usunięcia symboli.
- Test ze składnikami wielowyrazowymi (np. „olive oil”, „soy sauce”) - weryfikacja, że nie rozpadają się na pojedyncze słowa w chmurze.
- Test ze składnikami pomocniczymi (salt, water) - weryfikacja poprawnego odfiltrowania.
- Test słowa kluczowego bez asocjacji powyżej progu odcięcia - weryfikacja, że skrypt nie generuje błędu.
- Test powtarzalności - dwa kolejne uruchomienia dają identyczny układ chmur słów (set.seed).

Scenariusze użytkownika (user stories)

Scenariusz 1: Analiza dominujących trendów kulinarnych

- **Jako:** analityk danych / badacz.
- **Chcę:** poznać najczęściej występujące składniki w dużej bazie przepisów.
- **Aby:** zidentyfikować podstawowe bazy smakowe i fundamenty kuchni.

Kryteria akceptacji:

- Użytkownik może wczytać plik recipes.csv i uruchomić analizę.
- Skrypt zlicza globalną częstość składników i prezentuje wyniki w tabeli.
- Skrypt generuje czytelną chmurę częstości słów.
- Użytkownik może wskazać dominujące składniki.

Scenariusz 2: Wyodrębnienie składników charakterystycznych

- **Jako:** twórca aplikacji kulinarnej / system rekomendacji.
- **Chcę:** wskazać składniki najbardziej charakterystyczne dla poszczególnych przepisów.
- **Aby:** lepiej odróżniać przepisy od siebie i budować trafniejsze rekomendacje.

Kryteria akceptacji:

- Skrypt oblicza wagi TF-IDF i stosuje agregację maksymalną.
- Skrypt prezentuje tabelę wag unikalności oraz chmurę unikalności.
- Użytkownik może odróżnić składniki uniwersalne od wyróżniających dany przepis.

Scenariusz 3: Odkrywanie profili kulinarnych

- **Jako:** technolog żywności / autor książki kucharskiej.
- **Chcę:** poznać typowe powiązania i kolokacje pomiędzy składnikami.
- **Aby:** rozpoznać profile poszczególnych kuchni i tworzyć spójne kompozycje smakowe.

Kryteria akceptacji:

- Użytkownik może zdefiniować słowa kluczowe oraz próg odcięcia korelacji.
- Skrypt przekształca dane do macierzy TDM i wyznacza asocjacje dla każdego słowa kluczowego.
- Skrypt generuje wykresy lizakowe najsilniejszych powiązań.
- Użytkownik może zidentyfikować cztery odrębne światy kulturowo-kulinarne oraz stałe kolokacje (np. „soy sauce”, „vanilla extract”, „grated cheese”).