

Dokumentacja Specyfikacji Wymagań (SRS)

Software Requirements Specification

Projekt: Analiza składników różnych przepisów kulinarnych

Eksploracja danych tekstowych: analiza częstości słów, TF-IDF oraz analiza asocjacji

Przedmiot: Programowanie Systemów Informatycznych

Wersja dokumentu: 1.0

Data: 07.06.2026

Autorzy: Karolina Rybak, Hanna Jermakowicz, Anna Martyniuk

1. Wprowadzenie

Niniejszy dokument opisuje specyfikację wymagań dla skryptu napisanego w języku R, który realizuje eksplorację danych tekstowych na zbiorze przepisów kulinarnych. Dane wejściowe stanowi plik `recipes.csv` zawierający opisy przepisów wraz z listami składników. Celem systemu jest oczyszczenie i ustrukturyzowanie list składników, a następnie wydobywanie z nich trendów oraz wzorców przy pomocy metod analizy danych tekstowych (text mining).

System łączy trzy techniki eksploracji danych tekstowych: (1) analizę częstości występowania składników wraz z wizualizacją w postaci chmury słów, (2) analizę TF-IDF wyłaniającą składniki najbardziej charakterystyczne dla poszczególnych przepisów, oraz (3) analizę asocjacji (korelacji współwystępowania), która ujawnia stałe powiązania pomiędzy składnikami i odtwarza tzw. kolokacje kulinarne (np. „soy sauce”, „vanilla extract”). Spełnia to wymaganie zastosowania co najmniej dwóch poznanych technik analizy danych (w projekcie wykorzystano trzy).

Projekt został zrealizowany zgodnie z podejściem Reproducible Research: kod źródłowy oraz zestaw danych są dostępne w repozytorium GitHub w formacie umożliwiającym pełne odtworzenie analizy, a bezpośrednio ze skryptu R generowany jest raport w formacie HTML (z wykorzystaniem mechanizmu knitr/rmarkdown).

2. Cele systemu

- Wczytanie danych wejściowych z pliku `recipes.csv` z poprawnym kodowaniem znaków (Windows-1252).
- Oczyszczenie i normalizacja list składników: zamiana na małe litery, usunięcie nawiasów kwadratowych oraz znaków towarowych (®, ™, ©), usunięcie składników pomocniczych (sól, woda, pieprz) i typowych przymiotników (fresh, ground, chopped itp.).
- Zachowanie integralności składników wielowyrazowych (np. „olive oil”, „soy sauce”) jako pojedynczych tokenów w analizie częstości i TF-IDF.
- Zliczenie częstości występowania składników i przedstawienie wyników w formie tabeli oraz chmury słów.
- Wyłonienie składników najbardziej charakterystycznych dla pojedynczych przepisów metodą TF-IDF i ich wizualizacja.
- Wykrycie asocjacji (korelacji współwystępowania) pomiędzy wybranymi słowami kluczowymi a pozostałymi składnikami.
- Umożliwienie analizy unikalnych składników na podstawie czterech odrębnych światów kulturowo-kulinarnych.
- Wizualizacja wyników w postaci chmur słów oraz wykresów lizakowych (ggplot2).
- Interpretacja zidentyfikowanych trendów i wzorców kulinarnych.
- Zapewnienie powtarzalności analizy (ustawione ziarno losowości, raport HTML, repozytorium z kodem i danymi).

3. Wymagania funkcjonalne

3.1. Wczytywanie danych

- Skrypt powinien umożliwiać wczytanie danych z lokalnego pliku .csv (recipes.csv).
- Skrypt powinien poprawnie obsługiwać kodowanie pliku źródłowego (Windows-1252), tak aby znaki specjalne w nazwach handlowych były prawidłowo dekodowane.
- Skrypt powinien automatycznie generować unikalny indeks numeryczny dla każdego wiersza.

3.2. Przetwarzanie i oczyszczanie tekstu

- Skrypt powinien dokonywać bezpiecznej konwersji bajtowej plików wejściowych.
- Skrypt powinien normalizować tekst do małych liter.
- Skrypt powinien usuwać nawiasy kwadratowe oraz znaki towarowe (®, ™, ©).
- Skrypt powinien rozбивać listę składników na pojedyncze elementy (rozdzielone przecinkami).
- Skrypt powinien usuwać frazy zawierające „pepper”, składniki pomocnicze (salt, water) oraz typowe przymiotniki opisowe.
- Skrypt powinien usuwać puste oraz zbyt krótkie tokeny (o długości nie większej niż 2 znaki).
- Skrypt powinien łączyć składniki wielowyrazowe twardą spacją na potrzeby poprawnego wyświetlenia w chmurze słów.

3.3. Analiza częstości

- Skrypt powinien zliczać liczbę wystąpień poszczególnych składników.
- Skrypt powinien sortować składniki według częstości występowania.
- Skrypt powinien prezentować wyniki w formie tabeli (TOP 15) oraz chmury słów.

3.4. Analiza TF-IDF

- Skrypt powinien przeprowadzać analizę ważenia statystycznego i agregować wskaźniki dla każdego unikalnego słowa.
- Skrypt powinien agregować wynik poprzez wyznaczenie maksymalnej wartości TF-IDF dla każdego składnika (wskazanie składników najbardziej charakterystycznych).
- Skrypt powinien prezentować wyniki w formie tabeli (TOP 15) oraz chmury słów.

3.5. Analiza asocjacji

- Skrypt powinien budować macierz częstości terminów (TermDocumentMatrix) na podstawie oczyszczonych przepisów.
- Skrypt powinien przeszukiwać macierz TDM w pętli dla zestawu słów kluczowych.
- Skrypt powinien obliczać współczynnik korelacji liniowej Pearsona i filtrować wyniki dla zadanego progu odcięcia.
- Skrypt powinien prezentować najsilniejsze asocjacje w formie wykresów lizakowych.

3.6. Wizualizacja danych

- Skrypt powinien generować chmury słów (pakiet wordcloud z kolorystyką RColorBrewer).
- Skrypt powinien generować wykresy lizakowe asocjacji (pakiet ggplot2) zawierające tytuł, etykiety osi, wartości oraz legendę.
- Skrypt powinien generować cztery wykresy lizakowe do maksymalnie 25 największych wyników.

3.7. Parametryzacja i raportowanie

- Skrypt powinien umożliwiać modyfikację listy słów kluczowych oraz progu korelacji dla analizy asocjacji.
- Skrypt powinien umożliwiać modyfikację parametrów chmury słów (m.in. minimalnej częstości i maksymalnej liczby słów).
- Skrypt powinien umożliwiać wygenerowanie raportu w formacie HTML bezpośrednio ze skryptu R.

4. Wymagania нефunkcjonalne

4.1. Wydajność

- Analiza pełnego zbioru danych (ok. 5 475 przepisów) wraz z wygenerowaniem wszystkich wizualizacji powinna trwać nie dłużej niż 60 sekund na typowym komputerze osobistym.

4.2. Bezpieczeństwo

- System powinien zapewniać poprawność i kompletność danych wyjściowych.
- System powinien przetwarzać dane wyłącznie lokalnie, bez przesyłania ich na zewnątrz.

4.3. Powtarzalność (Reproducible Research)

- Ustawione ziarno losowości (set.seed) powinno gwarantować identyczny układ chmur słów przy każdym uruchomieniu skryptu.
- Kod źródłowy oraz dane powinny być dostępne w repozytorium GitHub w formacie umożliwiającym pełne odtworzenie wyników.
- Skrypt powinien udostępniać informacje o wersji środowiska i pakietów (sessionInfo) na potrzeby odtwarzalności.

4.4. Niezawodność

- Skrypt powinien poprawnie obsługiwać znaki specjalne oraz różne zapisy składników.
- Skrypt powinien poprawnie obsługiwać puste i zbyt krótkie tokeny oraz słowa kluczowe, dla których nie istnieją asocjacje powyżej progu (bez generowania błędów).

4.5. Użyteczność

- Wykresy powinny być czytelne i zawierać odpowiednie tytuły, etykiety osi oraz legendę.

- Chmury słów powinny być generowane z czytelną kolorystyką (RColorBrewer).
- Raport HTML powinien zawierać spis treści oraz możliwość zwijania bloków kodu (code folding).

4.6. Utrzymywalność i kompatybilność

- Kod powinien być czytelnie napisany: podzielony na sekcje i opatrzony komentarzami.
- Skrypt powinien być kompatybilny z R w wersji 4.0 lub nowszej.
- Skrypt powinien korzystać z bibliotek: tidyverse, tidytext, tm, wordcloud, RColorBrewer.
- Skrypt powinien wykorzystywać ścieżki względne, a dane powinny być dołączone do repozytorium (przenośność).

5. Interfejsy użytkownika

5.1. Wejście

- Plik danych recipes.csv (format CSV, kodowanie Windows-1252).
- Zmienne konfiguracyjne w kodzie: ścieżka do pliku (file_path), lista słów kluczowych (słowa), próg korelacji (cor_limit).

5.2. Sposób uruchomienia

- Wykonanie skryptu w środowisku R / RStudio.
- Wygenerowanie raportu HTML poprzez rmarkdown::render() lub funkcję „Compile Report” w RStudio.

5.3. Wyjście

- Tabele z 15 najczęstszymi oraz 15 najbardziej charakterystycznymi (TF-IDF) składnikami.
- Dwie chmury słów: chmura częstości oraz chmura TF-IDF.
- Cztery wykresy lizakowe przedstawiające asocjacje dla słów kluczowych: vanilla, soy, barbecue, parmesan.
- Raport HTML zawierający kod, wyniki i wizualizacje wraz ze spisem treści.

6. Wymagania dotyczące danych

Dane wejściowe są zapisane w pliku recipes.csv (ok. 5 475 wierszy) w języku angielskim. Plik zawiera następujące kolumny:

Kolumna	Opis
id	Tekstowy identyfikator przepisu.
recipeName	Nazwa przepisu.
rating	Ocena przepisu.
totalTimeInSeconds	Łączny czas przygotowania (w sekundach).

course	Typ dania (np. Desserts) — w nawiasach kwadratowych.
cuisine	Rodzaj kuchni (np. American) — w nawiasach kwadratowych.
ingredients	Lista składników w nawiasach kwadratowych, rozdzielona przecinkami — podstawowe pole analizy.

- Dane tekstowe są w języku angielskim; skrypt nie obsługuje analizy dla innych języków.
- Plik jest zapisany w kodowaniu Windows-1252 (zawiera m.in. znaki ® oraz ™ w nazwach handlowych składników).
- Kluczowym polem analizy jest kolumna ingredients; jej obecność jest wymagana do działania skryptu.
- System nie obsługuje danych z innych źródeł ani formatów niż plik CSV o opisanej strukturze.

Słownictwo dokumentacji

- **Token:** pojedynczy element tekstu (w tym projekcie — pojedynczy składnik lub słowo).
- **Składnik (ingredient):** element listy składników danego przepisu.
- **Indeks numeryczny (recipe_id):** unikalny identyfikator wiersza/przepisu zachowujący integralność danych po rozbiciu list składników na pojedyncze elementy.
- **Chmura słów (wordcloud):** graficzna prezentacja słów, w której rozmiar słowa odzwierciedla jego wagę (częstość lub TF-IDF).
- **Częstość globalna:** łączna liczba wystąpień danego składnika w całej bazie przepisów.
- **TF (Term Frequency):** częstość występowania składnika w obrębie pojedynczego przepisu.
- **IDF (Inverse Document Frequency):** miara rzadkości składnika w całym zbiorze przepisów.
- **TF-IDF:** iloczyn TF i IDF; wysoka wartość wskazuje składnik charakterystyczny dla danego przepisu.
- **Agregacja maksymalna:** wybór najwyższej wartości TF-IDF danego składnika spośród wszystkich przepisów (miara maksymalnej unikalności).
- **Waga unikalności:** wartość TF-IDF interpretowana jako stopień charakterystyczności składnika.
- **Korpus (corpus):** uporządkowany zbiór dokumentów tekstowych (tu: lista przepisów).
- **TermDocumentMatrix (TDM):** macierz częstości terminów w dokumentach, podstawa analizy asocjacji.
- **Asocjacja:** statystyczne powiązanie współwystępowania dwóch terminów.
- **Korelacja Pearsona:** miara siły liniowego współwystępowania terminów (zakres od -1 do 1).
- **Próg odcięcia (corlimit):** minimalna wartość korelacji, powyżej której asocjacja jest uwzględniana w wynikach.

- **Słowa nieistotne:** słowa pomijane w analizie, tu m.in. składniki pomocnicze i przymiotniki opisowe (np. salt, water, fresh, ground).
- **Konwersja bajtowa:** operacja sanityzacji znaków wykonywana na etapie wczytywania danych tekstowych.
- **Twarda spacja:** znak spacji nierozdzielającej (U+00A0) łączący składniki wielowyrazowe w jeden token.
- **Wykres lizakowy:** wykres łączący punkt z osią odcinkiem, prezentujący wartości dla poszczególnych słów.
- **Kolokacja:** stałe, powtarzalne połączenie wyrazów (np. „soy sauce”).
- **Cztery światy kulturowo-kulinarne:** zidentyfikowane w analizie grupy składników odpowiadające profilom kulinarnym (cukierniczy, azjatycki, grillowy, włoski).
- **EDA (Exploratory Data Analysis):** eksploracyjna analiza danych nakierowana na odkrywanie wzorców.
- **Reproducible Research:** podejście zapewniające pełną odtwarzalność wyników (dostępny kod i dane).

Przypadki użycia (use cases)

Aktor: Użytkownik

- wskazuje / wczytuje plik recipes.csv,
- uruchamia analizę (wykonuje skrypt),
- przegląda tabele wyników oraz wizualizacje,
- generuje raport HTML,
- (opcjonalnie) modyfikuje słowa kluczowe i próg korelacji dla analizy asocjacji.

Aktor: Skrypt / System

- wczytuje i poprawnie dekoduje dane,
- oczyszcza i normalizuje listy składników,
- zlicza częstość składników,
- oblicza wagi TF-IDF i wyłania składniki charakterystyczne,
- buduje macierz TDM i wyznacza asocjacje,
- generuje chmury słów oraz wykresy lizakowe,
- składa raport HTML z wynikami i wizualizacjami.

Testowe przypadki użycia

- Test z pełnym zbiorem recipes.csv (poprawne wczytanie ~5 475 przepisów).
- Test ze składnikami zawierającymi znaki towarowe (®, ™) — weryfikacja ich poprawnego usunięcia.
- Test ze składnikami wielowyrazowymi (np. „olive oil”, „soy sauce”) — weryfikacja, że nie rozpadają się na pojedyncze słowa w chmurze.

- Test z przepisem zawierającym wyłącznie składniki pomocnicze (salt, water) — weryfikacja poprawnego filtrowania.
- Test słowa kluczowego bez asocjacji powyżej progu — weryfikacja, że skrypt nie generuje błędu ani pustego wykresu.
- Test powtarzalności — dwa kolejne uruchomienia dają identyczny układ chmur słów (set.seed).

Scenariusze użytkownika (user stories)

Scenariusz 1: Analiza dominujących trendów kulinarnych

- **Jako:** analityk danych / badacz.
- **Chcę:** poznać najczęściej występujące składniki w dużym zbiorze przepisów.
- **Aby:** zidentyfikować podstawowe bazy smakowe i fundamenty kuchni.

Kryteria akceptacji:

- Użytkownik może wczytać plik recipes.csv i uruchomić analizę.
- Skrypt zlicza częstość składników i prezentuje tabelę TOP 15.
- Skrypt generuje czytelną chmurę słów odzwierciedlającą częstość.
- Użytkownik może wskazać dominujące składniki (np. garlic, olive oil, flour, eggs).

Scenariusz 2: Wyłonienie składników charakterystycznych

- **Jako:** twórca aplikacji kulinarnej / system rekomendacji.
- **Chcę:** wskazać składniki najbardziej charakterystyczne dla poszczególnych przepisów.
- **Aby:** lepiej odróżniać przepisy i budować trafniejsze rekomendacje.

Kryteria akceptacji:

- Skrypt oblicza wagi TF-IDF na poziomie przepis–składnik.
- Skrypt prezentuje tabelę TOP 15 oraz chmurę słów opartą na TF-IDF.
- Użytkownik może odróżnić składniki uniwersalne od wyróżniających dany przepis.

Scenariusz 3: Odkrywanie stałych połączeń składników

- **Jako:** technolog żywności / autor książki kucharskiej.
- **Chcę:** poznać typowe powiązania i kolokacje pomiędzy składnikami.
- **Aby:** rozpoznać profile poszczególnych kuchni i tworzyć spójne kompozycje smakowe.

Kryteria akceptacji:

- Użytkownik może zdefiniować słowa kluczowe oraz próg korelacji.
- Skrypt wyznacza asocjacje dla każdego słowa kluczowego.
- Skrypt generuje wykresy lizakowe najsilniejszych powiązań.
- Użytkownik może zidentyfikować stałe kolokacje (np. „soy sauce”, „vanilla extract”, „grated cheese”).